



**Kampus  
Merdeka**  
INDONESIA JAYA


# Pengantar Hadoop

Pertemuan 04

# ***Outline***

- Alur Analisis Big data
- Pengertian Hadoop
- Sejarah Singkat Hadoop
- Komponen Hadoop
- HDFS
- Pengertian MapReduce
- Map dan Reduce Tasks
- Aliran Data MapReduce
- Contoh Pemrosesan MapReduce (kasus)
- Map Tasks
- Ekstraksi
- Shuffle and Sort
- Reduce Tasks
- YARN
- Komponen YARN
- Prinsip Kerja YARN
- Kelemahan Hadoop
- Contoh kasus lain
- Tools yang dibutuhkan untuk implementasi Hadoop

# Alur Analisis Big Data




# Pengertian Hadoop

- Hadoop → software platform (platform perangkat lunak) sebagai analytic engine yang memungkinkan seseorang dengan mudah untuk melakukan pembuatan penulisan perintah (write) dan menjalankan (run) aplikasi yang memproses data dalam jumlah besar
- Hadoop → kerangka kerja sumber terbuka (lisensi Apache) untuk pemrosesan batch terdistribusi dari data skala besar menggunakan model pemrograman MapReduce.
- Model pemrograman MapReduce berguna untuk aplikasi di mana data yang terlibat sangat besar sehingga tidak akan muat pada satu mesin.
- Data biasanya disimpan pada sistem file terdistribusi (seperti Hadoop Distributed File System - HDFS).
- Program MapReduce memanfaatkan lokalitas data dan pemrosesan data berlangsung di node tempat data berada. Dengan kata lain, penghitungan dipindahkan ke tempat data berada, sebagai kebalikan dari cara tradisional memindahkan data dari tempatnya berada ke tempat perhitungan selesai

# Sejarah Singkat

- Dimulai dari penelitian berawal di Google tahun 2003
  - Tujuan Google untuk mengindeks seluruh World Wide Web
  - Google sudah mencapai batas dari skalabilitas di teknologi RDBMS
  - Pendekatan baru untuk menyimpan dan menganalisis data sangat besar
  - Google File System (Ghemawat, et al, 2003)
  - MapReduce: Simplified Data Processing on Large Clusters (Dean and Ghemawat, 2008)
- Developer bernama Doug Cutting (Yahoo!) berusaha untuk mengatasi masalah yang sama pada implementasi search engine open source buaatannya, Nutch
  - Memulai project open source berdasarkan penelitian Google dan membuat Hadoop 2005
  - Hadoop diberi nama dari nama mainan gajah anaknya


# Komponen Utama Hadoop



- Inti dari Hadoop terdiri dari 3 komponen utama:
  - Unit Penyimpanan: Hadoop Distributed File System (HDFS)
    - Media untuk mendistribusikan data ke cluster supaya bisa scalable dan cepat
  - Unit Pemrosesan: MapReduce
    - Unit untuk memproses data dengan cara yang handal (reliable) dan cepat
  - Resource Management Unit : YARN (Yet Another Resource Negotiator)
    - Scheduling dan management & monitoring

# HDFS

HDFS Architecture





- HDFS berguna sebagai direktori di komputer dimana data Hadoop disimpan.
- Untuk pertama kalinya, direktori ini akan di “format” agar dapat bekerja sesuai spesifikasi dari Hadoop.


- Data di Hadoop disimpan dalam cluster.
  - Cluster biasanya terdiri dari banyak node atau komputer/server.
  - Setiap node di dalam cluster ini harus terinstall Hadoop untuk bisa jalan.
  - Hadoop biasanya memiliki berapa jenis node di dalam cluster (tergantung versi):
    - NameNode:
      - Node utama yang mengatur penempatan data di cluster, menerima job dan program untuk melakukan pengolahan dan analisis data misal melalui Map Reduce.
      - menyimpan metadata tempat data di cluster dan juga replikasi data tersebut.
    - DataNodes:
      - Node tempat data ditempatkan.
      - Satu block di HDFS/datanode adalah 64 MB.
      - Sebaiknya data yang disimpan di HDFS ukurannya minimal 64 MB untuk memaksimalkan kapasitas penyimpanan di HDFS.

- Meskipun konteks yang dibicarakan adalah dalam cluster, Hadoop juga bisa dijalankan dalam single node
- Dalam single node maka semua peran di atas berada dalam satu komputer
- Biasanya single node ini digunakan hanya untuk training atau development. Bukan untuk produksi skala enterprise

# HDFS dan Unix File System


- Dalam beberapa hal, HDFS mirip dengan UNIX filesystem
- Hierarkis, dengan UNIX/style paths
  - Misal. /sales/reports/asia.txt
- File ownership dan permissions mirip UNIX
- Ada beberapa **perbedaan** mayor dari UNIX
  - Tidak ada konsep current directory
  - Tidak bisa memodifikasi file setelah dituliskan
    - Bisa menghapus dan membuat ulang, tetapi tidak bisa memodifikasi
  - Harus menggunakan utilities dari Hadoop atau kode buatan sendiri untuk mengakses HDFS

# HDFS <> YARN




# Arsitektur HDFS

- Hadoop memiliki arsitektur master/slave
- HDFS master daemon: Name Node
  - Mengatur namespace (pemetaan file ke block) dan metada (pemetaan block ke mesin/komputer)
- HDFS slave daemon: Data Node
  - Membaca dan menulis data sebenarnya
  - Dapat berjalan di atas filesystem sebenarnya (ext3/4, NTFS, dll)



## Contoh:

- NameNode berisi metadata untuk dua file
  - Foo.txt (300MB) dan Bar.txt (200MB)
  - Dimisalkan HDFS dikonfigurasi dengan block sebesar 128MB
- DataNodes berisi block data sebenarnya
  - Tiap block berukuran 128MB
  - Tiap block direplikasi 3x pada cluster
  - Laporan block dikirimkan ke NameNode secara periodik



# Mengakses HDFS Melalui Command Line






# Pengertian MapReduce

- Setelah mengetahui bagaimana Hadoop menyimpan data, maka berikutnya penting untuk memahami bagaimana Hadoop memproses data
- Pemrosesan data di Hadoop menggunakan MapReduce (MR)
- MR bukanlah suatu bahasa, tapi model pemrograman (salah satu bentuk data processing patterns) yang awalnya dikembangkan oleh Google
- MapReduce terdiri dari dua tugas (task):
  1. Map tasks
  2. Reduce tasks

# Map dan Reduce Tasks

- Map Tasks selalu berjalan lebih dulu
  - Biasanya digunakan untuk “memecah” data
  - Memfilter, metransformasi, parse data.
    - Misal parse simbol saham (stock), harga, dan waktu dari data feed
  - Output dari map tasks akan menjadi input dari reduce tasks
- Reduce Tasks
  - Biasanya digunakan untuk menggabungkan (aggregate) data dari map tasks. Misal. Menghitung harga rata-rata per-jam dari saham
  - Tidak selalu diperlakukan jadi bisa bersifat optional
    - Kadang bisa juga melakukan job “map-only”
- Antara dua tasks ini ada fase tersembunyi yang dikenal dengan nama **“Shuffle and Sort”**
  - Mengatur output map untuk dikirimkan ke reducer
- kerangka kerja MapReduce tidak bergantung pada satu bahasa tertentu.
  - Kode program MapReduce dapat ditulis dalam Java, Python, atau bahasa pemrograman lainnya.

# Aliran Data MapReduce



# Contoh Pemrosesan MapReduce

- Contoh Jobs/Tasks pada MapReduce:
  - *Input*: file teks berisi order id, employee name, dan sale amount
  - *Output*: jumlah seluruh sales per employee

## Job Input

|   |        |      |
|---|--------|------|
| 0 | Alice  | 3625 |
| 1 | Bob    | 5174 |
| 2 | Alice  | 893  |
| 3 | Alice  | 2139 |
| 4 | Diana  | 3581 |
| 5 | Carlos | 1039 |
| 6 | Bob    | 4823 |
| 7 | Alice  | 5834 |
| 8 | Carlos | 392  |
| 9 | Diana  | 1804 |


## Job Output

|        |       |
|--------|-------|
| Alice  | 12491 |
| Bob    | 1431  |
| Carlos | 9997  |
| Diana  | 5385  |


# Map Tasks

- Hadoop memecah job menjadi map tasks secara individual
  - Jumlah map tasks ditentukan oleh banyaknya data input
  - Tiap map task menerima sebagian dari keseluruhan job input untuk diproses secara paralel
  - Mapper memproses satu input record dalam satu waktu
  - Untuk tiap input record, dihasilkan nol atau lebih record sebagai output
- Dalam kasus ini, 5 map tasks masing-masing mem-parse sebagian dari input record
  - Misal: output-nya adalah employee name dan sales

# Ekstraksi



# Shuffle and Sort dalam MapReduce




# Shuffle and Sort

- Hadoop secara otomatis melakukan sort dan merge output dari seluruh map tasks
  - Mengurutkan record berdasarkan key (misal nama)
    - Proses ini dikenal sebagai “Shuffle and Sort”
    - Hasilnya digunakan untuk reduce tasks



# Shuffle and Sort of Case



# Reduce Tasks

- Input pada reducer berasal dari shuffle and sort
  - Seperti map, fungsi reduce menerima satu record satu waktu
  - Suatu reducer menerima semua record dari suatu key
  - Untuk tiap input record, reduce dapat menghasilkan nol atau lebih output record
- Dalam kasus ini, fungsi reduce menjumlahkan total sales per employee
  - Menghasilkan employee name (key) dan total sales sebagai output dalam bentuk sebuah file
  - Tiap file output reducer dituliskan ke directory job tertentu di HDFS

# Reduce Tasks Total Sales per Employee

Input to Reduce Task #1

Reducer menjumlahkan sales

Input to Reduce Task #2

|        |      |
|--------|------|
| Alice  | 3625 |
| Alice  | 893  |
| Alice  | 2139 |
| Alice  | 5834 |
| Carlos | 1039 |
| Carlos | 392  |


|       |      |
|-------|------|
| Bob   | 5174 |
| Bob   | 4823 |
| Diana | 3581 |
| Diana | 1804 |

Job Output  
(Output of Reduce Tasks)

|        |       |
|--------|-------|
| Alice  | 12491 |
| Carlos | 1431  |

|       |      |
|-------|------|
| Bob   | 9997 |
| Diana | 5385 |

# Alur Semua Proseses Map and Reduce Tasks



# Keunggulan MapReduce

- Sederhana (beserta fault tolerance)
  - Terutama dibandingkan dengan model pemrograman terdistribusi lainnya
- Fleksibel
  - Menyediakan kemampuan analitik dan bekerja dengan banyak tipe data dibandingkan SQL
- Skalabilitas
  - Berjalan secara paralel antar cluster


# YARN (Yet Another Resource Negotiator)

- YARN aka YARN Daemon → Hadoop Resource Management
- YARN → Lapisan (layer) pemrosesan dari Hadoop yang bertugas sebagai unit alokasi sumber daya Hadoop.
- YARN → Mengatur permintaan pekerjaan dan mengalokasikan sumber daya sesuai ketersediaan dan atas permintaan klien
- YARN memungkinkan beberapa mesin pemroses data untuk berjalan dalam single cluster Hadoop
  - Batch program (mis. Spark, MapReduce)
  - Interactive SQL (mis. Impala)
  - Analitik lanjut (mis. Spark, Impala)
  - Streaming (mis. Spark Streaming)

# Komponen YARN


1. **Resource Manager** → bertindak sebagai master daemon dan bertanggungjawab dalam penugasan CPU, memori, dll.
2. **Node Manager** → bekerja sebagai slave daemon dan melaporkan pekerjaannya kepada Resource Manager.
3. **Application Master** → yang bekerja dengan Resource Manager dan Node Manager dalam menegosiasikan sumber daya.

# Prinsip Kerja YARN







# Prinsip Kerja YARN..



# Prinsip Kerja YARN...




# HDFS >< YARN




# Kelemahan Hadoop

- Map Reduce hanya bisa berjalan dalam mode analisis batch (secara periodic) dan tidak bisa terus menerus secara realtime → Hal ini membuat Map Reduce tidak bisa mengolah data dalam bentuk *streaming* tanpa henti seperti misalnya tweet dari Twitter.

# Contoh Lain (1)



# Contoh Lain (2)



# Tools yang dibutuhkan untuk implementasi Hadoop

- JAVA JDK
- Hadoop Binary
- Hadoop bin master: Winutils-master (at github)
- Code editor: VS Code/Notepad++
- Python





**TERIMA KASIH**